

Formulário de Estatística Não Paramétrica

Luís Israel

3 de julho de 2018

1. Binomial

$$P(X = i) = \binom{n}{i} p_0^i (1 - p_0)^{n-i}$$

Teste exato para amostras com variáveis binárias.

$$H_0 : p = p_0 \dots$$

$$H_1 : p \neq p_0 \dots$$

2. Runs

1. Se necessário, classificar o vetor como valores positivos e negativos, normalmente em relação à mediana
2. Contar o o número de sequências r , o número de valores positivos n_1 e o número de valores negativos n_2
3. Comparar r com seus respectivos valores críticos na tabela binomial

Teste para amostras com variáveis binárias.

H_0 : a sequência foi produzida aleatoriamente

H_1 : a sequência não foi produzida aleatoriamente

3. Independência qui-quadrado

$$\chi_0^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}}$$

$$E_{i,j} = \frac{n_i n_j}{n}$$

$$\chi_0^2 > \chi_{\alpha, (r-1)(c-1)}^2$$

Teste de independência entre amostras não pareadas.

H_0 : as variáveis são independentes

H_1 : as variáveis são dependentes

$$\phi = \sqrt{\frac{\chi^2}{n}}$$

$$\rho_{X,Y} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y}$$

$$T = \sqrt{\frac{\phi^2}{\sqrt{(r-1)(c-1)}}}$$

$$V = \sqrt{\frac{\chi^2}{nt}}, t = \min(r-1, c-1)$$

4. McNemar

T1	T2	Total	
B1	a	b	a + b
B2	c	d	c + d
Total	a + c	b + d	n

$$\chi_0^2 = \frac{(b - c)^2}{b + c}$$

$$\chi_0^2 > \chi_{\alpha, 1}^2$$

Teste de homogeneidade de frequências marginais para amostras pareadas.

$$H_0 : p_b = p_c$$

$$H_1 : p_b \neq p_c$$

5. Sinal

1. Calcular a diferença entre os vetores
2. Classificar o novo vetor como valores positivos e negativos
3. Fazer o teste binomial com o novo vetor

Teste de comparação entre amostras pareadas.

$$H_0 : p = p_0 \dots$$

$$H_1 : p \neq p_0 \dots$$

Wilcoxon

1. Para $i = 1, \dots, N$ calcular $|x_{2,i} - x_{1,i}|$ e $\text{sgn}(x_{2,i} - x_{1,i})$
2. Excluir pares onde $|x_{2,i} - x_{1,i}| = 0$. N_r é o tamanho da amostra reduzida
3. Ordenar os pares e atribuir um rank R_i a eles

$$W = \sum_{i=1}^{N_r} \text{sgn}(x_{2,i} - x_{1,i}) R_i$$

$$|W| > W_{\alpha, N_r}$$

6. Q de Cochran

Tratamento	1 Tratamento	2 Tratamento	k
Bloco 1	x_11	x_12	x_1k
Bloco 2	x_21	x_22	x_2k
Bloco b	x_b1	x_b2	x_bk

$$T = k(k-1) \frac{\sum_{j=1}^k (X_{oj} - \frac{N}{k})^2}{\sum_{i=1}^b X_{io} (k - X_{io})}$$

$$T > \chi^2_{\alpha, k-1}$$

7. Mann-Whitney

Ordenar os dados de todos os grupos de 1 a N. Em caso de empate, o rank dos itens é a média dos ranks que receberiam caso não houvesse empate. O menor U é a estatística usada no teste.

$$U_i = R_i - \frac{n_i(n_i + 1)}{2}$$

8. H de Kruskal-Wallis

Ordenar os dados de todos os grupos de 1 a N. Em caso de empate, o rank dos itens é a média dos ranks que receberiam caso não houvesse empate.

$$H = (N-1) \frac{\sum_{i=1}^g n_i (\bar{r}_{io} - \bar{r})^2}{\sum_{i=1}^g \sum_{j=1}^{n_i} (r_{ij} - \bar{r})^2}$$

$$H > \chi^2_{\alpha, g-1}$$

Teste de comparação entre amostras pareadas.

H_0 : as amostras são de populações iguais

H_1 : as amostras são de populações diferentes

Teste de comparação entre amostras pareadas com variáveis binárias.

H_0 : os tratamentos tem efeitos iguais

H_1 : os tratamentos tem efeitos diferentes

onde

k é o número de tratamentos

X_{oj} é o número total de colunas para o j^o tratamento

b é o número de blocos

X_{io} é o número total de linhas para o i^o bloco

N é o total absoluto

Teste de comparação entre dois grupos de amostras não pareadas.

H_0 : as amostras são de populações iguais

H_1 : as amostras são de populações diferentes

onde

R_i é a soma dos ranks no grupo i

n_i é o número de observações no grupo i

Teste de comparação entre i grupos de amostras não pareadas.

H_0 : as amostras são de populações iguais

H_1 : as amostras são de populações diferentes

onde

n_i é o número de observações no grupo i

r_{ij} é o rank da observação j do grupo i

N é o número total de observações

entre os grupos

$\bar{r}_{io} = \frac{\sum_{j=1}^{n_i} r_{ij}}{n_i}$ é o rank médio de todas as observações no grupo i

$\bar{r} = \frac{1}{2}(N+1)$ é a média de todos os r_{ij}

Mediana de Mood

1. Calcular a mediana de todos os dados.
2. Dividir cada grupo em duas categorias: uma com a contagem de itens menores ou iguais à mediana; outra com a contagem de itens maiores que a mediana.
3. Formatar numa tabela de contingência e realizar o teste qui quadrado.

Teste de comparação entre amostras não pareadas.

H_0 : as amostras são de populações com medianas iguais

H_1 : as amostras são de populações com medianas diferentes

9. Friedman

Dada uma matriz $(x_{ij})_{n \times k}$ com n blocos e k tratamentos, calcular os ranks *dentro* de cada bloco. Em caso de empate, o rank dos itens é a média dos ranks que receberiam caso não houvesse empate. Criar uma nova matriz $(r_{ij})_{n \times k}$ onde cada r_{ij} é um rank.

Teste de comparação entre amostras pareadas.

H_0 : os tratamentos tem efeitos iguais

H_1 : os tratamentos tem efeitos diferentes

$$Q = \frac{SS_t}{SS_e}$$

$$Q > \chi^2_{\alpha, k-1}$$

onde

$$SS_t = n \sum_{j=1}^k (\bar{r}_{.j} - \bar{r})^2$$

$$SS_e = \frac{1}{n(k-1)} \sum_{i=1}^n \sum_{j=1}^k (r_{ij} - \bar{r})^2$$

$$\bar{r}_{.j} = \frac{1}{n} \sum_{i=1}^n r_{ij}$$

$$\bar{r} = \frac{1}{nk} \sum_{i=1}^n \sum_{j=1}^k r_{ij}$$

10. Coeficiente de Spearman

Ordenar as variáveis em rankings de acordo com o grupo. A segunda fórmula só funciona quando não há empates.

Coeficiente de correlação entre rankings de variáveis.

$H_0 : \rho = 0$

$H_1 : \rho \neq 0$

$$\rho = r_s = \frac{cov(r_{gX}, r_{gY})}{\sigma_{r_{gX}} \sigma_{r_{gY}}} = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

11. Siegel-Tukey

1. Ordenar os dados de todos os grupos de 1 a N de forma alternada (rank 1 é o menor, 2 e 3 são os dois maiores, 4 e 5 são os próximos menores, etc)
2. Aplicar o teste de Mann-Whitney

Teste de comparação para amostras não pareadas.

$$H_0 : \sigma_A^2 = \sigma_B^2$$

$$H_1 : \sigma_A^2 > \sigma_B^2$$

12. Coeficiente de Kendall

$$\tau = \frac{1}{n(n-1)} \sum_{i \neq j} \text{sgn}(x_i - x_j)(y_i - y_j)$$

Coeficiente de correlação entre rankings de variáveis.

$H_0 : \tau = 0$

$H_1 : \tau \neq 0$

Coeficiente Kappa

$$\kappa = 1 - \frac{1 - p_o}{1 - p_e}$$

Coeficiente de concordância entre classificadores.

$H_0 : \tau = 0$

$H_1 : \tau \neq 0$

p_o : concordância relativa observada

p_e : concordância relativa esperada

13. Kolmogorov-Smirnor

Ordenar os dados no formato $\{Y_1 < \dots < Y_n\}$.

$$D = \max_{1 \leq i \leq N} \left(F(Y_i) - \frac{i-1}{N}, \frac{i}{N} - F(Y_i) \right)$$

Anderson-Darling

Ordenar os dados no formato $\{Y_1 < \dots < Y_n\}$.

$$A^2 = -n - S$$

$$S = \sum_{i=1}^n \frac{2i-1}{n} [\ln(\Phi(Y_i)) + \ln(1 - \Phi(Y_{n+1-i}))]$$

Referências

Material do prof Quinino

<https://de.wikipedia.org/wiki/Binomialtest>

<https://itl.nist.gov/div898/handbook/eda/section3/eda35d.htm>

https://en.wikipedia.org/wiki/Chi-squared_test

https://en.wikipedia.org/wiki/McNemar%27s_test

https://en.wikipedia.org/wiki/Sign_test

https://en.wikipedia.org/wiki/Cochran%27s_Q_test

https://en.wikipedia.org/wiki/Kruskal%E2%80%93Wallis_one-way_analysis_of_variance

https://en.wikipedia.org/wiki/Median_test

<https://www.isixsigma.com/tools-templates/hypothesis-testing/understanding-uses-moods-median-test/>

https://en.wikipedia.org/wiki/Friedman_test

https://en.wikipedia.org/wiki/Siegel%E2%80%93Tukey_test

https://en.wikipedia.org/wiki/Spearman%27s_rank_correlation_coefficient

https://en.wikipedia.org/wiki/Siegel%E2%80%93Tukey_test

https://en.wikipedia.org/wiki/Cohen%27s_kappa

<http://uregina.ca/~gingrich/ch11a.pdf>

<https://www.itl.nist.gov/div898/handbook/eda/section3/eda35g.htm>

https://en.wikipedia.org/wiki/Anderson%E2%80%93Darling_test

https://en.wikipedia.org/wiki/Mann%E2%80%93Whitney_U_test

https://en.wikipedia.org/wiki/Wilcoxon_signed-rank_test

Teste para distribuições contínuas de uma dimensão. A estatística deve ser comparada aos valores críticos de uma tabela própria.

H_0 : os dados seguem a distribuição especificada

H_1 : os dados não seguem a distribuição especificada

F é a função da distribuição cumulativa teórica

Teste para distribuições contínuas de uma dimensão. A estatística deve ser comparada aos valores críticos da distribuição teórica.

H_0 : os dados seguem a distribuição especificada

H_1 : os dados não seguem a distribuição especificada